1 Questão 1 – pré-processamento e limpeza textual

1.1 Dados e auditoria

Foi utilizada a configuração `ptbr` do corpus ASSIN, com 2500 pares no treino, 500 na validação e 2000 no teste. Cada par tem uma premissa e uma hipótese em português brasileiro, um `relatedness_score` (similaridade, de 1 a 5) e um rótulo `entailment_judgment`: 0 = *none*, 1 = *entailment* e 2 = *paraphrase*, conforme a documentação do corpus no Hugging Face. O `sentence_pair_id` é apenas um identificador e o `relatedness_score` não é usado como entrada do classificador, pois é uma anotação humana fortemente associada ao rótulo.

Antes de limpar, os dados foram auditados para que cada etapa fosse justificada por evidência:

- não há valores nulos, textos vazios nem pares duplicados, e nenhum par de validação ou teste aparece no treino;
- as frases são curtas (média de 13 palavras, máximo de 25);
- não há URLs, HTML, menções, *hashtags* nem caracteres corrompidos;
- há ruído tipográfico leve: aspas curvas (61 frases no treino), travessões (11) e espaços duplos (2);
- há muitos números, `R$` e `%` (1805, 210 e 232 frases no treino), que costumam ser decisivos para a relação entre as frases;
- cerca de 7% a 10% das frases contêm palavras de negação, em todas as classes.

1.2 Etapas aplicadas e justificativas

- **Normalização.** Normalização Unicode (NFC), padronização de aspas e travessões, colapso de espaços e conversão para minúsculas. Essas operações não alteram o significado. O texto é passado ao analisador com as maiúsculas originais, para que nomes próprios e lemas sejam reconhecidos corretamente, e só depois convertido para minúsculas. Acentos, números, `R$` e `%` foram mantidos.
- **Remoção de ruído.** Apenas a pontuação foi removida na etapa de *tokens*. Como a auditoria não encontrou URLs, HTML nem menções, não foram aplicadas remoções para esses padrões.
- **Tokenização.** Realizada com o modelo `pt_core_news_sm` do spaCy, que trata melhor casos como `R$ 3,8`, palavras com hífen e abreviações do que a separação simples por espaços.
- **Lematização.** Escolhida em vez de *stemming* porque produz palavras reais e legíveis, reduzindo o vocabulário sem truncar os termos. O vocabulário do treino passou de 10029 *tokens* distintos para 7812 lemas.
- **Stopwords.** Foi gerada uma versão sem stopwords (7595 lemas distintos; 35639 palavras no total, contra 64800 *tokens*), mas com uma lista de 39 palavras protegidas que nunca são removidas: negações (*não, nunca, sem, nem, nenhum...*), quantificadores (*mais, menos, muito, pouco, todo...*) e palavras de restrição ou contraste (*apenas, somente, mas, porém, ainda, já...*). Remover a negação tornaria uma premissa e sua negação artificialmente

parecidas, o que prejudicaria a tarefa. As versões com e sem stopwords foram mantidas separadas, para comparar seu efeito nos classificadores.

- **Premissa e hipótese.** Foram processadas separadamente, com as mesmas regras, preservando sua ordem.

Os arquivos originais foram preservados. Os dados processados mantêm as colunas originais e acrescentam, para cada texto, as versões normalizada, em *tokens*, em lemas e em lemas sem stopwords.

1.3 Desbalanceamento

No treino, a classe 0 tem 1947 exemplos (77,9%), a classe 1 tem 437 (17,5%) e a classe 2 tem 116 (4,6%); validação e teste têm proporções semelhantes. Por isso a acurácia isolada seria enganosa, e serão usadas métricas por classe (*precision*, *recall* e F1, incluindo o F1 macro). Foram preparadas duas alternativas, ambas calculadas somente a partir do treino:

- **pesos de classe**, proporcionais ao inverso da frequência (0,428; 1,907; 7,184);
- ***oversampling* aleatório** das classes minoritárias até 1947 exemplos cada, com semente fixa.

A validação e o teste não foram alterados, para refletir a distribuição real. O *oversampling* duplica exemplos da classe 2 cerca de 17 vezes, o que pode levar o modelo a memorizá-los; por isso as duas estratégias serão comparadas na validação, e não combinadas, antes de decidir qual usar.

1.4 Verificação

Um *script* de verificação confere, nos três conjuntos, que o número de linhas, os identificadores, os rótulos, as pontuações de similaridade e os textos originais permanecem inalterados; que não há valores nulos nem textos vazios nas versões processadas; que a normalização removeu aspas curvas, travessões e espaços duplicados; e que todas as palavras protegidas, incluindo as negações, sobrevivem à remoção de stopwords. Também foram inspecionados exemplos antes e depois do processamento.

1.5 Limitações

O lematizador do modelo pequeno do spaCy pode errar em palavras raras, e trechos em inglês (como títulos de álbuns) não recebem tratamento específico. A lista de palavras protegidas é uma decisão do grupo e pode ser ajustada conforme os resultados dos classificadores.