1 Questão 2 – análise exploratória do corpus

A análise usa os dados processados na Questão 1. As estatísticas de tamanho e de distribuição de classes cobrem os três conjuntos; as análises de palavras e as representações numéricas usam apenas o treino, para não consultar validação e teste. Os rótulos e o `relatedness_score` servem só para colorir gráficos e avaliar resultados, e nenhum modelo é treinado com eles nesta questão.

1.1 Tamanho do corpus e número de classes

O corpus tem 5000 pares de frases (2500 no treino, 500 na validação e 2000 no teste), 130184 *tokens* e 14497 palavras distintas. O problema tem três classes: *none* (0), *entailment* (1) e *paraphrase* (2).

Conjunto	Pares	*Tokens*	Vocabulário	Lemas distintos	Aparecem 1 vez
Treino	2500	64800	10029	7812	4368
Validação	500	12848	3543	2947	1811
Teste	2000	52536	8646	6786	3853
Total	5000	130184	14497	11202	5981

Tabela 1: Tamanho do corpus processado.

As premissas têm em média 14,0 *tokens* e as hipóteses, 12,0. No treino, as premissas de *entailment* são mais longas (15,6 *tokens*) que suas hipóteses (11,3), enquanto em *paraphrase* os dois tamanhos são quase iguais (13,4 e 13,3).

1.2 Distribuição de classes

	Treino		Validação		Teste	
Classe	n	%	n	%	n	%
0 – *none*	1947	77,9	384	76,8	1553	77,6
1 – *entailment*	437	17,5	92	18,4	341	17,0
2 – *paraphrase*	116	4,6	24	4,8	106	5,3

Tabela 2: Distribuição das classes por conjunto.

As classes são fortemente desbalanceadas: no treino, a maior classe tem 16,8 vezes mais exemplos que a menor, e a proporção é parecida nos três conjuntos (Tabela 2 e Figura 1). Por isso a acurácia isolada seria enganosa e as classes minoritárias exigem atenção nas etapas seguintes. O `relatedness_score` cresce com a classe (média de 2,74 em *none*, 3,97 em *entailment* e 4,88 em *paraphrase*), com faixas de valores quase disjuntas: de 1 a 4,5, de 3 a 5 e de 4 a 5, respectivamente.

1.3 Frequência de palavras

As análises desta seção usam lemas sem *stopwords*, exceto nos casos indicados. As palavras mais frequentes do treino são *não* (378 ocorrências), *ano* (339), *mais* (243), *já* (203), *ainda* e *dia* (159 cada). Várias delas são palavras funcionais que foram protegidas na Questão 1 (negação, quantificação e contraste), o que mostra que essa proteção preserva termos de alta frequência. A Figura 2 mostra que as palavras mais frequentes são semelhantes nas três classes.

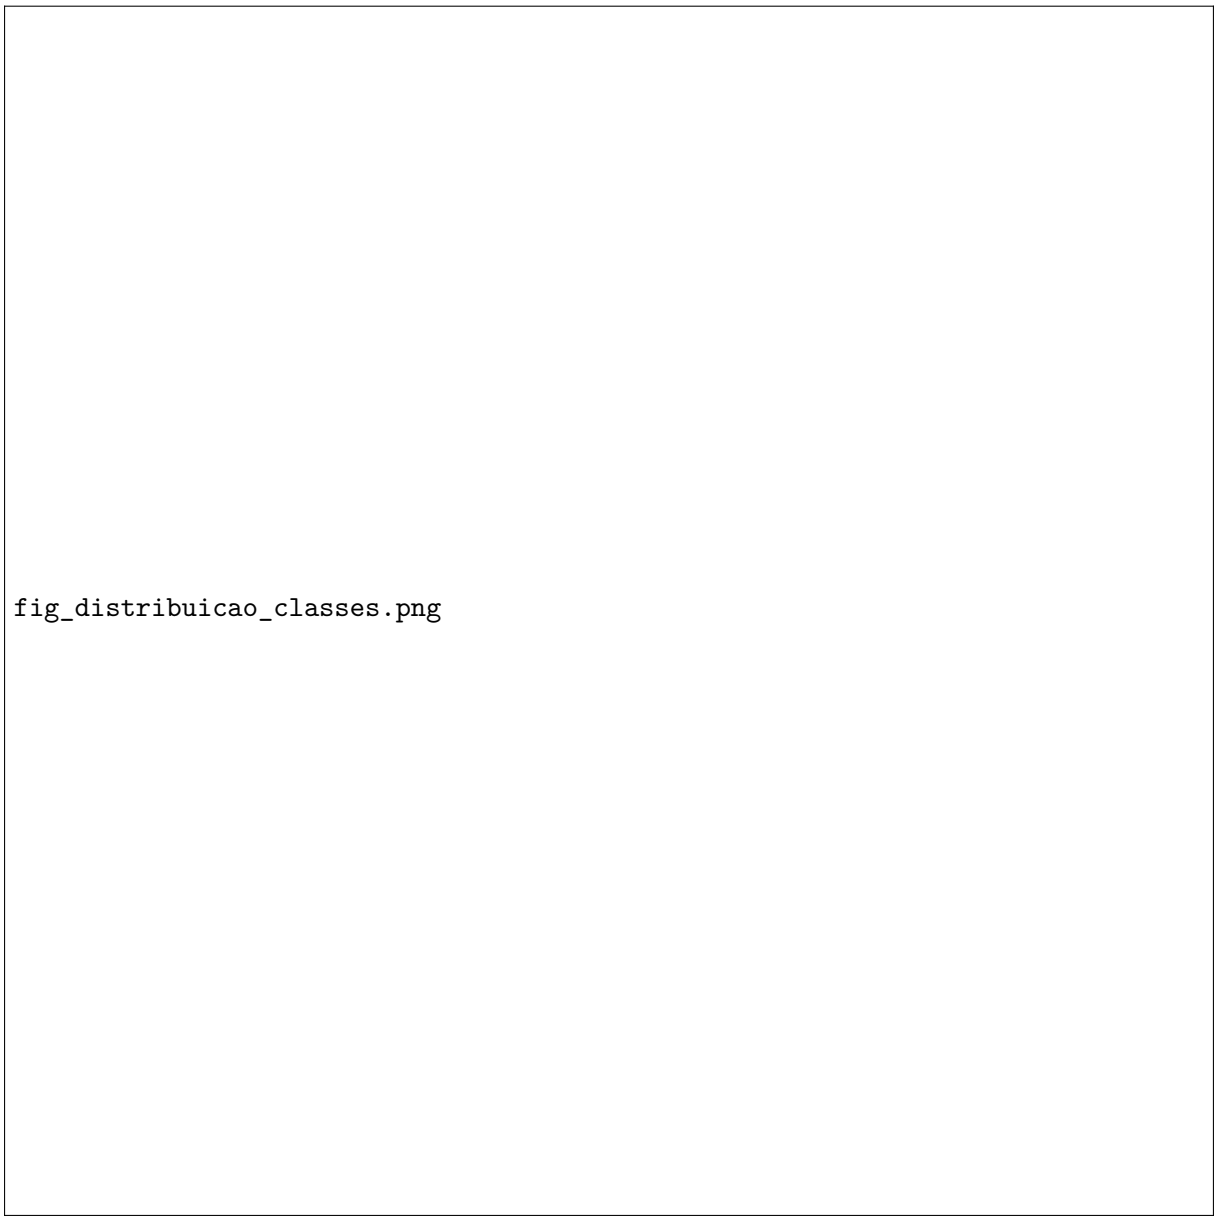


Figura 1: Distribuição das classes: contagem no treino e proporção por conjunto.

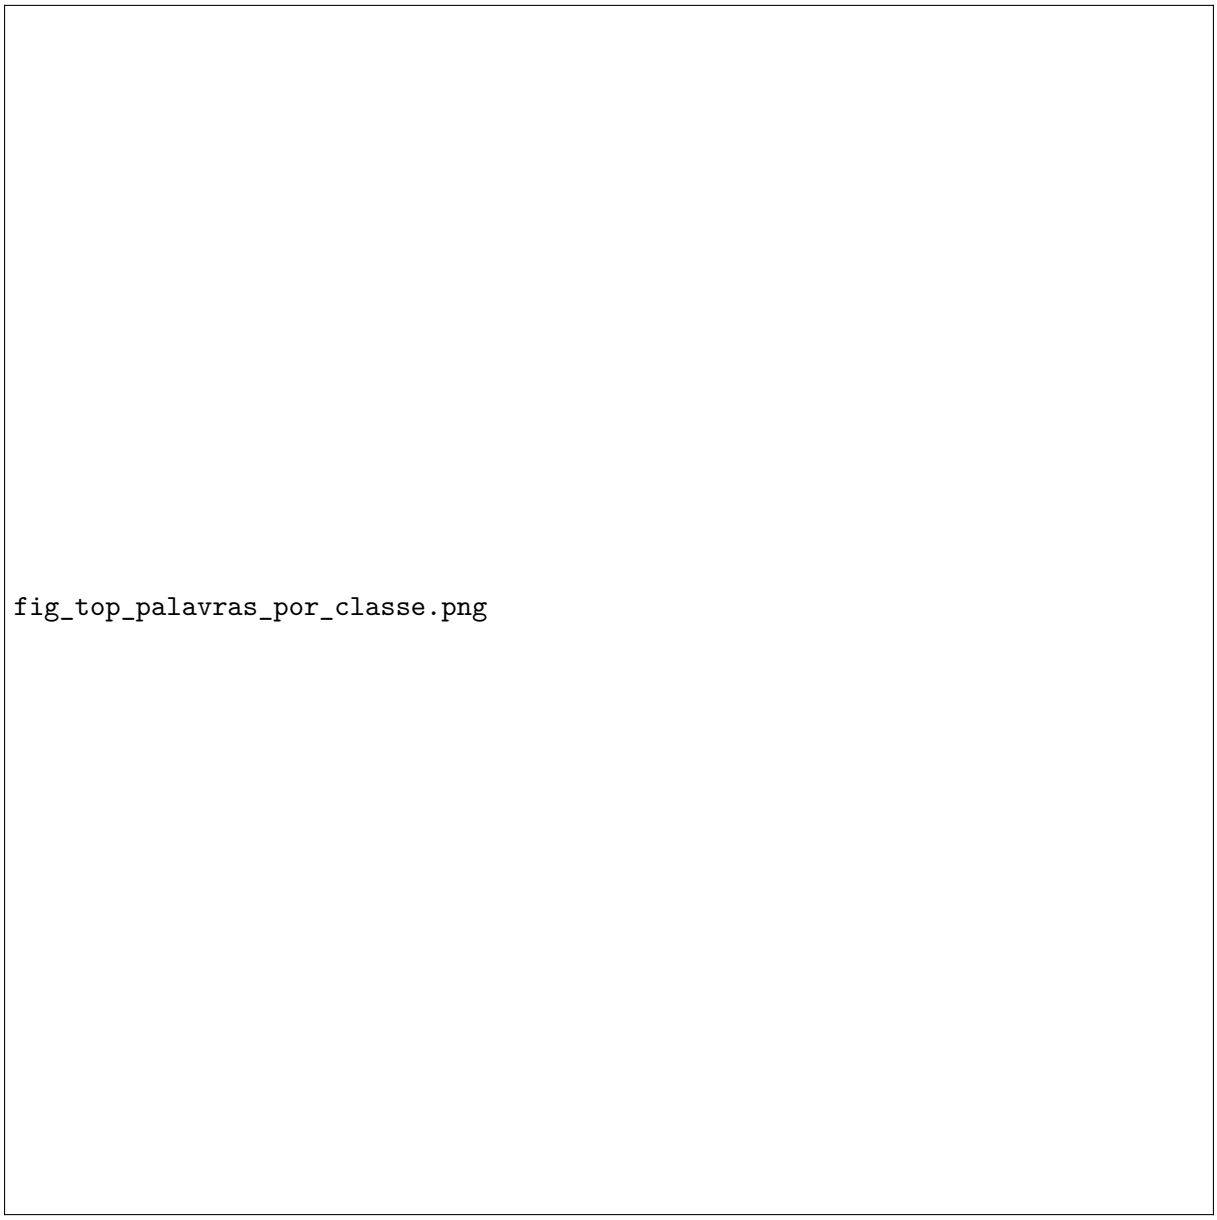


Figura 2: Lemas mais frequentes em cada classe (treino).

As palavras mais distintivas de cada classe (razão de frequências relativas, só para palavras com pelo menos 10 ocorrências) são, em sua maioria, ligadas a assuntos específicos (*google*, *superávit* e *treinador* em *none*; *cumprir*, *terça* e *cemitério* em *entailment*; *pesquisa*, *doação* e *líquido* em *paraphrase*) e não indicam um vocabulário próprio de cada relação. As nuvens de palavras (Figura 3) mostram o mesmo padrão: o vocabulário é de textos jornalísticos, com política, esporte e economia, e quase não varia entre as classes. Nas nuvens foram omitidas as palavras funcionais, que ocupariam quase todo o espaço.



Figura 3: Nuvens de palavras (lemas de conteúdo, treino): todas as classes e cada classe separadamente.

A distribuição de frequências segue aproximadamente a lei de Zipf (Figura 4): a inclinação da reta em escala logarítmica, nas 1000 primeiras posições, é $-0{,}88$. Das 10029 palavras do treino, 4368 (43,6%) aparecem uma única vez, e as 10 mais frequentes cobrem 22,9% dos *tokens*. Essa cauda longa de palavras raras indica um vocabulário esparso para um corpus de 2500 pares.

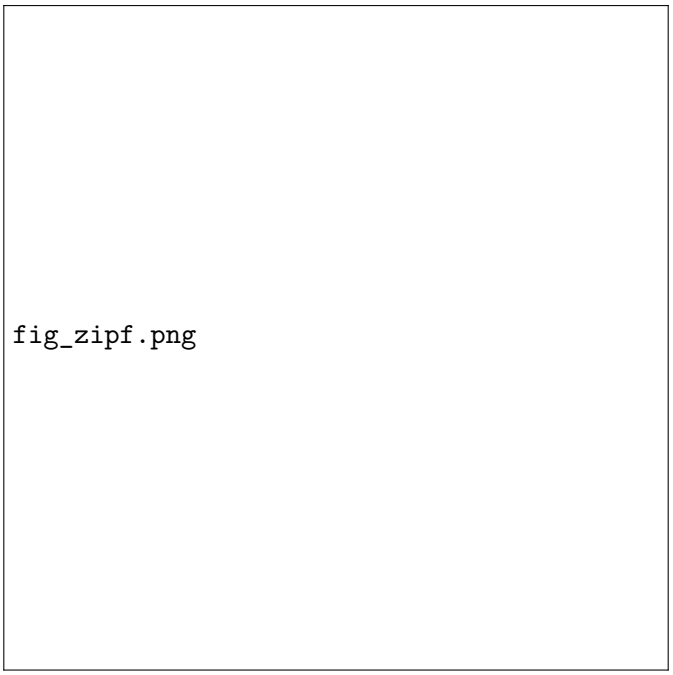


Figura 4: Frequência × posição dos *tokens* do treino, em escala logarítmica.

1.4 Negação e sobreposição lexical

Duas características se diferenciam entre as classes. A primeira é a negação: nos pares *none*, 14,5% têm negação em apenas uma das frases, contra 5,0% em *entailment* e 5,1% em *paraphrase* (Tabela 3). A segunda é a sobreposição de palavras entre premissa e hipótese, medida pelo índice de Jaccard: média de 0,24 em *none*, 0,40 em *entailment* e 0,47 em *paraphrase* (Figura 5). As distribuições se sobrepõem bastante, de modo que a sobreposição lexical ajuda, mas não basta para decidir a classe.

Classe	Em nenhuma	Nas duas	Só na premissa	Só na hipótese
none	83,7	1,8	8,0	6,5
entailment	89,2	5,7	3,4	1,6
paraphrase	87,9	6,9	1,7	3,4

Tabela 3: Presença de palavras de negação nos pares (% por classe, treino).

1.5 Conversão para dataset numérico

O corpus foi convertido em duas representações numéricas, ambas ajustadas somente no treino e aplicadas à validação e ao teste:

- **TF-IDF do par**: matriz esparsa com o texto da premissa e da hipótese (lemas sem *stopwords*), 3367 termos (palavras com ao menos 2 ocorrências no treino) e peso $1 + \log(tf)$. Apenas 0,28% das células são diferentes de zero.
- **Atributos de relação** (13 colunas): cosseno TF-IDF entre premissa e hipótese, índice de Jaccard, proporção da hipótese contida na premissa e vice-versa, número de lemas de cada frase, diferença de tamanho, contagem de negações em cada frase, indicador de negação assimétrica, quantidade de números em cada frase e indicador de números iguais.

O `relatedness_score`, o identificador e o rótulo ficam em arquivos separados e não entram nas

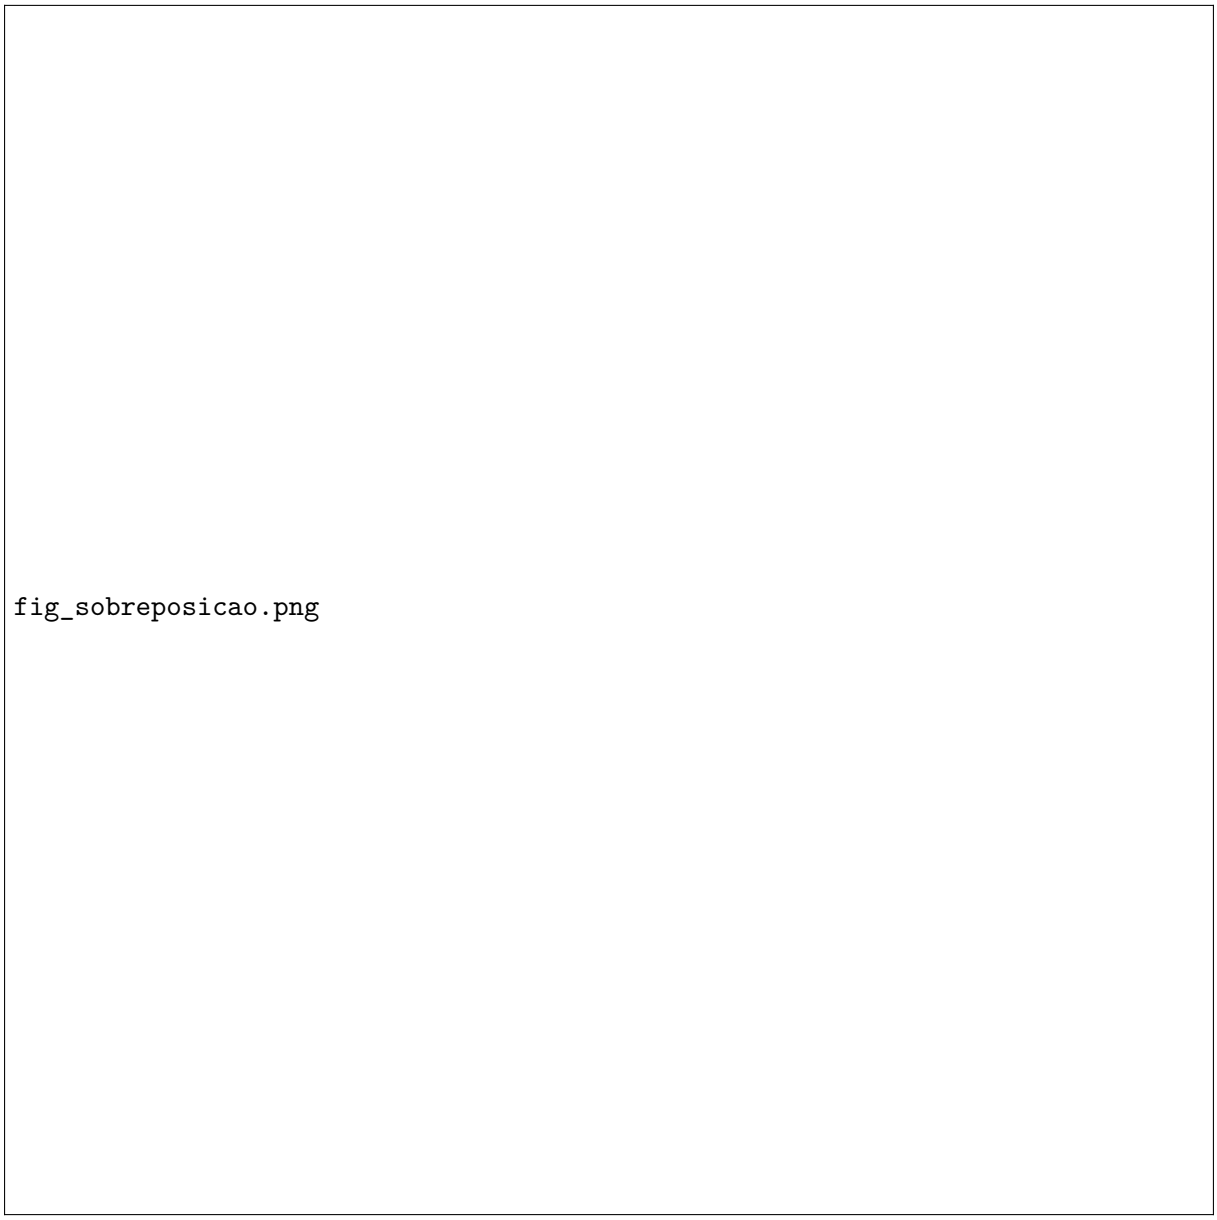


Figura 5: Sobreposição lexical (Jaccard) entre premissa e hipótese, por classe.

matrizes.

1.6 Aplicações de aprendizado não supervisionado

Foram exploradas cinco aplicações sobre o treino. Em todas, os rótulos servem apenas para interpretar os resultados.

1. Redução de dimensionalidade e visualização. Com SVD truncado, 2 componentes do TF-IDF explicam apenas 0,9% da variância (4,1% com 10, 13,0% com 50 e 20,8% com 100), o que mostra que o texto é de alta dimensão e pouco redundante. Já nos atributos de relação, o PCA concentra 27,8% e 18,9% da variância nos dois primeiros componentes: o primeiro agrupa as medidas de sobreposição (Jaccard, contenção e cosseno) e o segundo, as relacionadas a números e negação. A Figura 6 mostra que as classes ficam misturadas em todas as projeções. O *silhouette* dos rótulos é $-0{,}12$ no SVD do TF-IDF, $+0{,}10$ no PCA e $-0{,}08$ no t-SNE dos atributos de relação, ou seja, os atributos de relação separam um pouco mais, mas sem formar grupos nítidos.

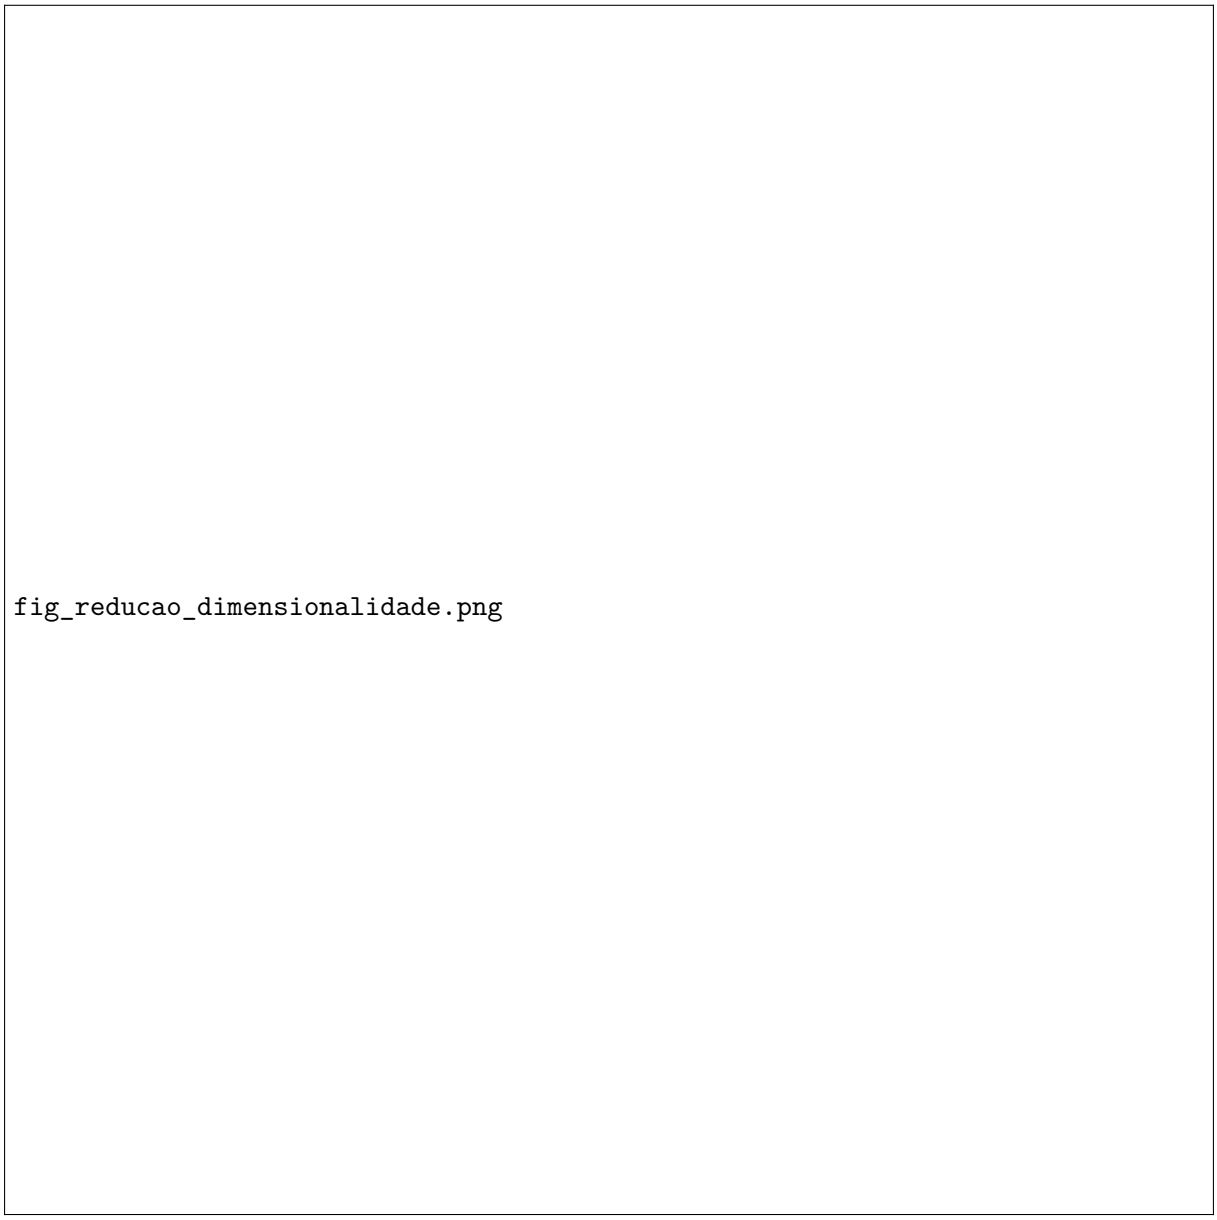


Figura 6: Projeções em duas dimensões, coloridas pela classe (usada só para colorir).

2. Agrupamento (K-Means). Aplicado aos atributos de relação padronizados, o melhor k pelo *silhouette* é 7 (0,214), mas com $k = 3$ (0,181) a comparação com as três classes é direta. Os clusters têm perfis interpretáveis (Tabela 4): o cluster 0 é o dos pares com negação assimétrica (83% dos seus pares); o cluster 1 tem alta sobreposição lexical (Jaccard médio de 0,40) e reúne cerca de 76% dos pares de *entailment* e 79% dos de *paraphrase*; o cluster 2 tem baixa sobreposição e é quase todo *none*. A concordância com as classes é baixa (ARI = 0,10; NMI = 0,11), pois o agrupamento só capta relações lexicais. Aplicado ao conteúdo (TF-IDF reduzido por SVD), o *silhouette* é muito baixo (0,047 com $k = 12$) e os clusters correspondem a assuntos (política, futebol, loteria, operação Lava Jato), sem relação com as classes (ARI = −0,02).

Cluster	n	*none* (%)	*entailment* (%)	*paraphrase* (%)
0	368	86,1	10,9	3,0
1	943	55,1	35,2	9,7
2	1189	93,4	5,5	1,2

Tabela 4: K-Means ($k = 3$) sobre os atributos de relação: composição de cada cluster.

3. Modelagem de tópicos (NMF). A fatoração não negativa do TF-IDF com 8 tópicos recupera assuntos coerentes: futebol (gol, jogo, minuto, partida), política (presidente, Dilma Rousseff, ministro, Senado), loterias (R$, bilhão, quina, prêmio), operação Lava Jato, balança comercial (superávit, US$, acumular), acidentes e vítimas (ferida, morrer, desaparecido), entre outros. O peso médio de cada tópico é parecido nas três classes (Figura 8); as diferenças são pequenas, e a classe *paraphrase* tem apenas 116 exemplos. Portanto o assunto do par não prevê a relação entre as frases.

4. Similaridade não supervisionada. O cosseno TF-IDF entre premissa e hipótese é uma medida de similaridade que não usa rótulos. Ele tem correlação de Spearman de 0,45 com o `relatedness_score` (0,58 para o índice de Jaccard), e sua AUC é de 0,77 para separar *none* das demais classes e de 0,76 para isolar *paraphrase*. O cosseno médio é 0,40 em *none*, 0,57 em *entailment* e 0,62 em *paraphrase* (Figura 9). A similaridade lexical, sozinha, já tem sinal, mas é limitada por não captar paráfrases com palavras diferentes nem negações.

5. Detecção de anomalias. O *Isolation Forest*, com 2% de contaminação, sinalizou 50 pares atípicos nos atributos de relação (31 *none*, 11 *entailment* e 8 *paraphrase*). A taxa de sinalização é maior em *paraphrase* (6,9%) que em *none* (1,6%) e *entailment* (2,5%). Os pares mais atípicos incluem frases sem relação aparente classificadas como *none* e paráfrases com muitos números iguais. Atipicidade não significa erro de anotação, mas a lista serve para uma revisão manual.

1.7 Conclusões da análise exploratória

- O corpus é pequeno (2500 pares de treino), com vocabulário esparso e forte desbalanceamento (16,8:1).
- O assunto das frases não distingue as classes; o que as distingue é a relação entre premissa e hipótese.
- Sobreposição lexical, negação assimétrica e números iguais trazem sinal, mas sozinhos separam as classes apenas parcialmente. Isso sugere combinar atributos de relação com representações que capturem o significado.
- As técnicas não supervisionadas aplicadas (redução de dimensionalidade, agrupamento, tópicos, similaridade e anomalias) ajudam a interpretar os dados, mas não substituem um

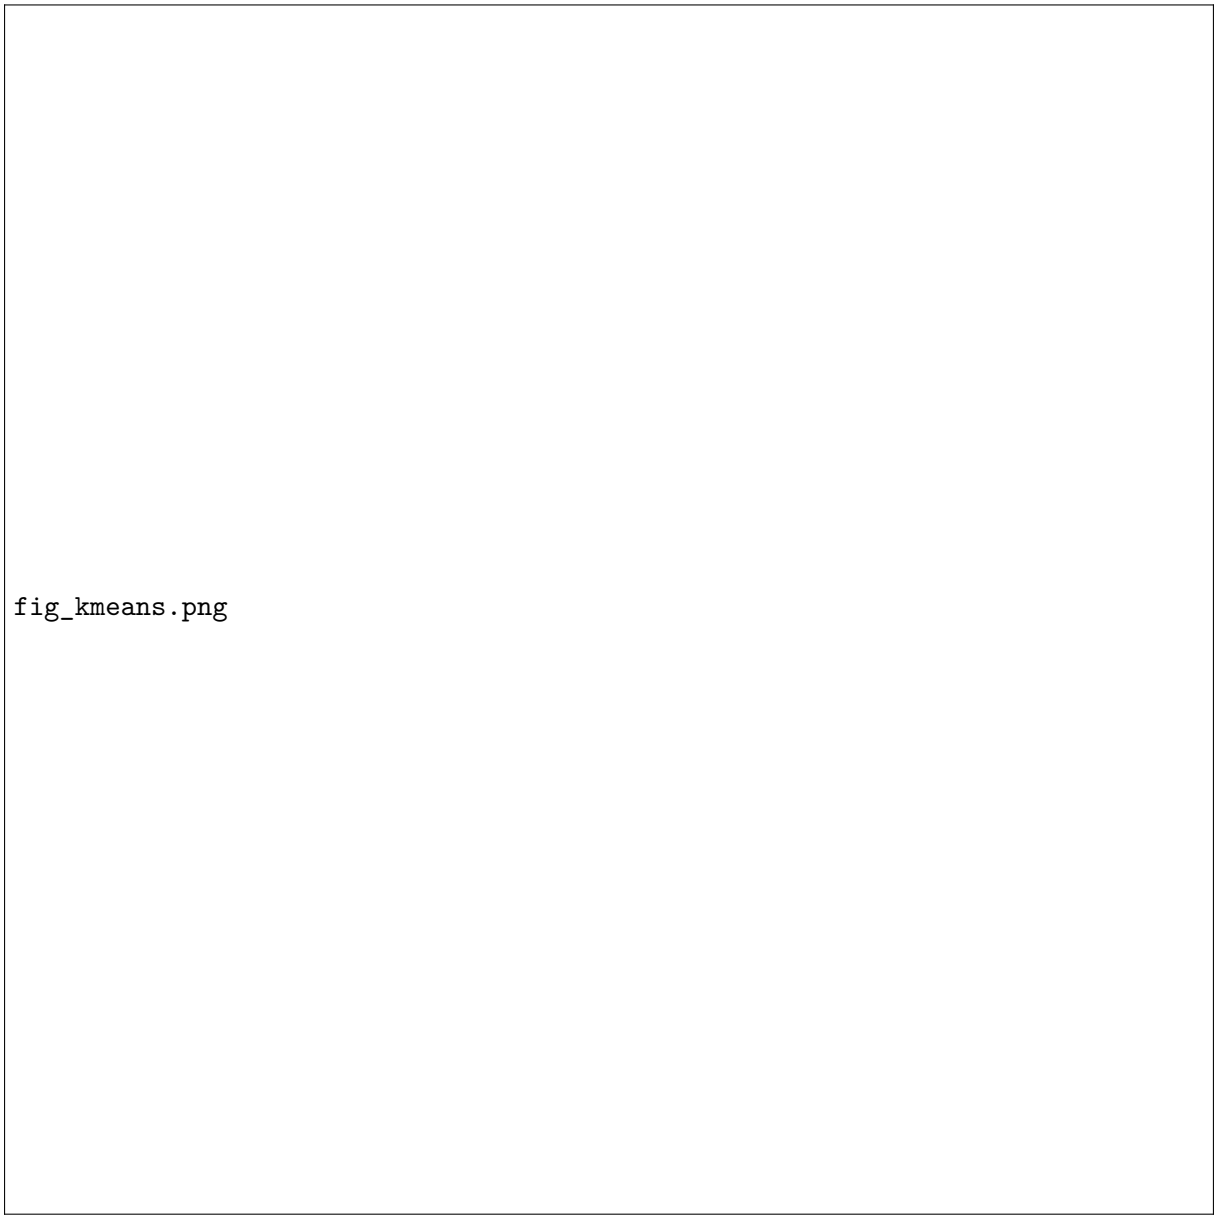


Figura 7: K-Means: escolha de k, composição dos clusters de relação e sua posição no plano PCA.

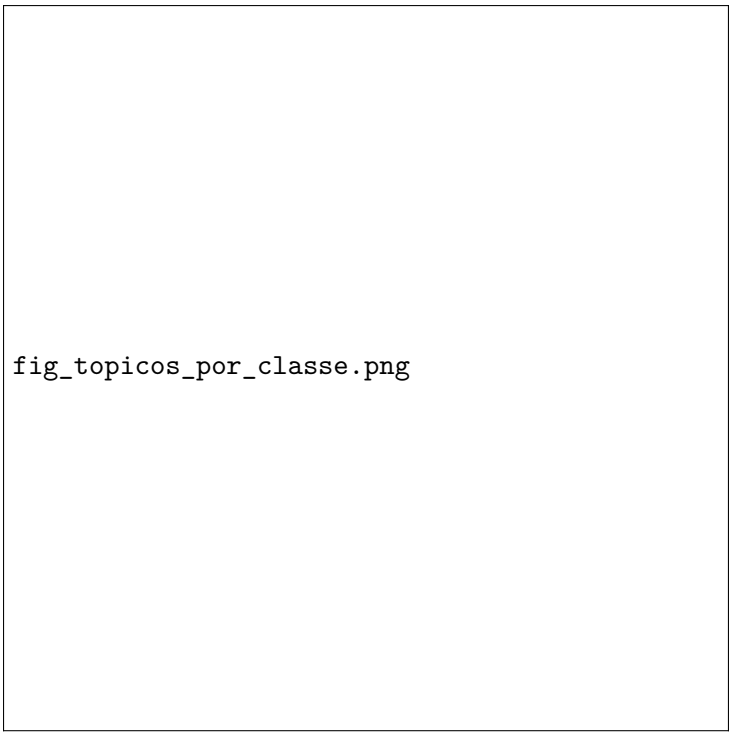


Figura 8: Peso médio dos tópicos NMF por classe (%).

classificador supervisionado.

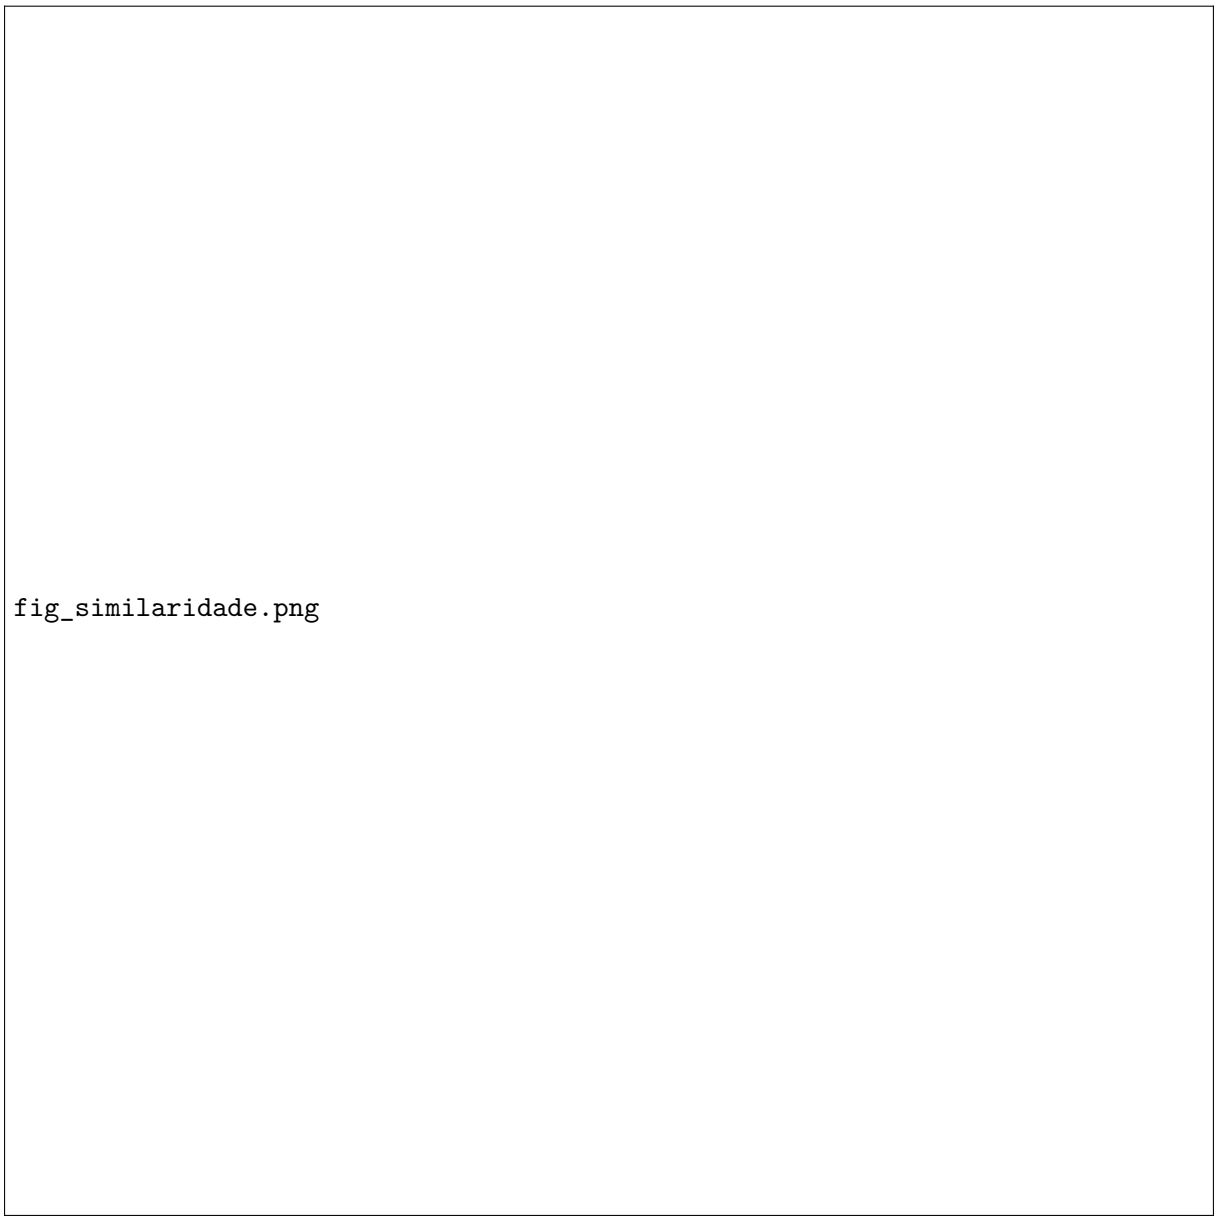


Figura 9: Cosseno TF-IDF contra `relatedness_score` e por classe.